

Lavoro in generale molto ben fatto. Il confronto tra Bayes e un'ottimizzazione Reglin/OLS è informativo e ben discusso. Bene l'attenzione e valutazione i modelli e loro errori. Tuttavia l'uso
Esperienza 5 - Gruppo D delle covarianze nei ALS

9.5

Confronto tra modelli a goccia per le masse nucleari non sembra congruente.

Dave Parmegiani

Enrico Vianelli

Luca Vettore

Francesco Paris

1 Introduzione

Nel contesto della fisica nucleare, è canonico approssimare le masse nucleari con una formula semi-empirica basata sul modello a goccia. L'obiettivo di questo lavoro è di sfruttare l'inferenza bayesiana per stimare i parametri di detto modello.

Considereremo tre diverse formule con differenti livelli di dettaglio, e dopo aver trovato i parametri di ciascuna vogliamo anche quantitativamente confrontare le bontà delle diverse descrizioni. Infine, ci concentreremo sulla formula più estesa per trarre un paragone tra approccio bayesiano, approccio frequentista e un approccio basato sul *machine learning*.

2 Descrizione dei dati

I dati sperimentali a cui facciamo riferimento sono quelli della *Atomic Mass Evaluation 2020* [1, 2], specificamente il documento *mass.mas20* [3]. Le osservabili che consideriamo sono il numero di neutroni N , il numero di protoni

Z , il numero totale di nucleoni A , l'energia di legame per nucleone B/A e l'errore su quest'ultima.

Escludiamo i dati relativi al singolo neutrone e al singolo protone, poiché le loro energie di legame sono definite a zero. Escludiamo poi tutti i nuclei le cui energie di legame provengono da predizioni teoriche piuttosto che da misurazioni sperimentali. In totale, consideriamo quindi 2458 nuclei sui 3556 iniziali. I dati considerati sono illustrati in Fig. 1.

3 Modello teorico

I nuclei atomici sono formati da neutroni aventi carica elettrica nulla, e protoni aventi carica elettrica positiva. L'interazione coulombiana spingerebbe questi sistemi a disgregarsi, tuttavia grazie all'interazione nucleare forte i nucleoni rimangono legati.

Per i nucleoni è energeticamente conveniente formare stati legati, come dimostrato dall'osservazione che le masse dei nuclei sono minori delle somme delle masse dei nucleoni




Figura 1: Dati sperimentali da noi considerati delle energie di legame per nucleone, in funzione del numero di nucleoni. Sono graficate anche le barre di errore, ma sono così piccole da risultare invisibili.

costituenti. L'energia di legame è quindi definita come

$$B(Z, N) = Nm_n + Zm_p - M(Z, N) > 0, \quad (1)$$

dove m_n è la massa di un neutrone nel vuoto, m_p è la massa di un protone nel vuoto e M è la massa del nucleo in questione.

Uno dei modelli più utilizzati per descrivere l'energia di legame è il modello a goccia. Questo modello descrive i nuclei atomici come gocce sferiche di liquido incompressibile. In questo lavoro consideriamo tre diverse formulazioni di questo modello, corrispondenti a tre livelli di dettaglio in ordine crescente.

3.1 Formula di Bethe-Weizsäcker (BW)

Il primo modello che consideriamo è la formula di Bethe-Weizsäcker [4]:

$$B_{BW}(Z, N) = a_v A + a_s A^{2/3} + a_c \frac{Z^2}{A^{1/3}} + a_{sy} \frac{(N - Z)^2}{A} \quad (2)$$

I termini, in ordine, sono:

- *Contributo di volume.* L'interazione nucleare è a corto raggio, quindi un nucleone risente dell'interazione con tutti e soli i suoi primi vicini. Questo è l'unico contributo che ci aspettiamo essere attrattivo in questo modello.
- *Contributo di superficie.* I nucleoni esterni hanno meno vicini con cui interagire, quindi questa è una correzione al contributo di volume.
- *Contributo coulombiano.* La repulsione coulombiana tra protoni abbassa l'energia di legame.
- *Termine di simmetria.* I nuclei con lo stesso numero di protoni e neutroni sono tipicamente maggiormente legati. Questa correzione è puramente empirica ed approssima un effetto quantistico.

Nella forma canonica di Eq. (2) in realtà è presente anche un quinto termine, detto di accoppiamento. Al fine di avere un riferimento più semplice possibile, abbiamo deciso di escludere il termine di accoppiamento dal primo modello.

3.2 Bethe-Weizsäcker con termine di accoppiamento (BW+PT)

Il secondo modello coincide con la formula di Bethe-Weizsäcker a cui aggiungiamo il termine di accoppiamento:

$$B_{BW+PT}(Z, N) = B_{BW} + a_p \frac{(-1)^Z + (-1)^N}{2A^{1/2}} \quad (3)$$

Anche questo contributo è puramente empirico e approssima l'effetto quantistico dovuto allo spin dei nucleoni. Si tratta infatti di una rudimentale descrizione del fenomeno di accoppiamento tra nucleoni dello stesso tipo.

In Eq. (3) riportiamo il termine di accoppiamento esplicitamente, che ci aspettiamo essere attrattivo per nuclei con sia Z che N pari, nullo per nuclei con A dispari, e repulsivo per nuclei con sia Z che N dispari.

3.3 Modello esteso (BW+PT+5T)

Il terzo e ultimo modello è la formula di Bethe-Weizsäcker estesa con 5 ulteriori termini [5]:

$$B_{BW+PT+5T}(Z, N) = B_{BW+PT} + a_w \frac{|N - Z|}{A} + a_{xc} \frac{Z^{4/3}}{A^{1/3}} + a_{st} \frac{(N - Z)^2}{A^{4/3}} + a_{RA} A^{1/3} + f(P) \quad (4)$$

I termini aggiuntivi, in ordine, sono:

- *Termine di Wigner.* Rafforza ulteriormente l'idea del contributo di simmetria, secondo cui nuclei con lo stesso numero di protoni e neutroni sono maggiormente legati.
- *Contributo di scambio coulombiano.* La descrizione quantistica della repulsione coulombiana tra protoni prevede una correzione al contributo classico.
- *Contributo di simmetria di superficie.* I nucleoni esterni contribuiscono diversamente al termine di simmetria rispetto a quelli interni. Questa è quindi una correzione al contributo di simmetria.
- *Contributo di curvatura.* La superficie del nucleo ha una curvatura non-nulla, che influenza il contributo di superficie.
- *Correzione di shell.* Il modello a goccia non è fondamentalmente in grado di descrivere la struttura a *shell* del nucleo. Questa è una correzione che cerca di compensare suddetta carenza del modello.

In particolare, la correzione di *shell* è espressa in funzione del cosiddetto fattore di Casten P [6]. Decidiamo di parametrizzare la correzione come un polinomio di secondo grado:

$$f(P) = \alpha_m P + \beta_m P^2 \quad (5)$$

Per calcolare P ci serve specificare la serie di numeri magici del modello a *shell*. Ci riferiamo alla convenzione per cui protoni e neutroni hanno gli stessi numeri magici, e sono $\{2, 8, 20, 28, 50, 82, 126, 184\}$. La convenzione scelta è in realtà arbitraria, poiché non si trova in letteratura un accordo unanime. Siccome i nuclei che consideriamo non superano i 184 protoni o neutroni, non serve specificare numeri magici più grandi.

4 Metodi computazionali

4.1 Inferenza bayesiana

Per svolgere le inferenze, definiamo una *likelihood* partendo dalle assunzioni canoniche che ciascuna misura sperimentale segua una distribuzione normale e che le misure siano indipendenti tra loro. Questo vuol dire che la *likelihood* sarà una distribuzione gaussiana centrata sui

Anche spiegare come si calcola il quantile P

dati sperimentali. Gli errori sperimentali nei nostri dati sono estremamente piccoli, quindi decidiamo in ciascun modello di introdurre un parametro di errore teorico ϵ sommato in quadratura a quello sperimentale.

In Sez. 3 abbiamo formulato i modelli in modo che tutti i parametri fossero di segno concorde, così da facilitarne la lettura. Sarà il segno del valore inferito del parametro a stabilire se il termine corrispondente sia attrattivo o repulsivo. In Tab. 1 riportiamo i *prior* da noi scelti, non-informativi e basati sui valori reperibili in letteratura [5]. Per quanto riguarda ϵ scegliamo invece un *prior* log-uniforme, il cui estremo inferiore sia confrontabile con gli errori sperimentali, e il cui estremo superiore sia comparabile al massimo residuo previsto per questi modelli [5].

Per svolgere l'inferenza bayesiana, impieghiamo un metodo di *nested sampling* ed in particolare utilizziamo l'implementazione disponibile nella libreria Python *ultranest* [7]. Nell'eseguire la simulazione, lasciamo tutte le impostazioni di default. Il vantaggio di usare *ultranest* è che questa libreria calcola anche la *evidence* durante l'inferenza.

Una volta svolta l'inferenza bayesiana su due diversi modelli H_1 e H_2 (che assumiamo egualmente probabili a priori), possiamo confrontarli quantitativamente utilizzando il fattore di Bayes. Questo è definito come il rapporto Z_1/Z_2 , dove le Z sono le rispettive *evidence*. Il significato di questo rapporto è che se risulta maggiore di 1 allora i dati sperimentali favoriscono il modello H_1 rispetto al modello H_2 , e viceversa. Nell'analisi calcoleremo i fattori di Bayes in forma logaritmica, ossia $\Delta \ln Z$, così da controllare quanto aumentare il livello di dettaglio fisico nel modello migliori effettivamente la descrizione statistica.

4.2 Approccio frequentista e approccio machine learning

Oltre all'inferenza bayesiana, presentiamo due metodi basati rispettivamente su un approccio frequentista e su tecniche di *machine learning*, concentrandoci sul modello esteso.

L'approccio frequentista consiste nel considerare il modello espresso da Eq. (4) e svolgere una regressione minimizzando gli scarti quadratici pesati. Per svolgere questo calcolo, sfruttiamo la funzione *curve_fit* della libreria Python *scipy* [8]. Oltre a restituire i valori ottimali dei parametri, questa funzione restituisce anche la matrice delle covarianze. Come errori sui valori dei parametri

Questo non dà incertezze sui parametri, misura solo la correlazione tra i vari parametri, usiamo dunque le corrispondenti deviazioni standard, che saranno tipicamente molto più piccole delle larghezze delle *posterior* bayesiane.

Il metodo basato sul *machine learning* è implementato usando la libreria Python *sklearn* [9], e consiste dapprima nel calcolo dei parametri su un sottoinsieme di dati detto di *training*, seguito da una verifica dell'efficacia predittiva del modello sui dati rimanenti detti di *test*. La regressione in questo caso è eseguita dalla classe *LinearRegression*, che per un modello lineare nei parametri restituisce gli stessi valori del già citato *curve_fit*, pur calcolandoli per via analitica anziché iterativa. La differenza tra i due approcci, infatti, risiede nella convalida del modello piuttosto che nel calcolo dei parametri. Vogliamo verificare se il modello sia concretamente in grado di predire nuovi dati non utilizzati nell'ottimizzazione. Per farlo, utilizziamo convalide incrociate basate su misure di performance, dette *score*.

Il primo *score* che consideriamo è il coefficiente di determinazione R^2 , definito come

$$R^2 = 1 - \frac{\sum_i (y_i - f_i)^2}{\sum_i (y_i - \bar{y})^2}, \quad (6)$$

dove le y_i sono i dati di *test*, n il loro numero, $\bar{y}$ la loro media algebrica, e le f_i sono le predizioni del modello ottimizzato sui dati di *training*. Il coefficiente R^2 assume valori compresi tra 0 nel caso di ipotesi nulla, e 1 nel caso di modello perfetto. Per calcolare questo coefficiente, dedichiamo il 70% dei dati al *training* e il rimanente 30% al *test*, scelti casualmente. Svolgiamo la convalida incrociata 1000 volte, così da avere una statistica sullo *score* ottenuto.

Il secondo *score* che consideriamo è l'errore quadratico medio (MSE), definito come

$$\text{MSE} = \frac{1}{n} \sum_i (y_i - f_i)^2, \quad (7)$$

che è esattamente lo stesso criterio con cui calcoliamo la regressione in primo luogo. Il MSE è definito positivo, e più è vicino allo zero e migliore è il modello. Stavolta, effettuiamo una convalida incrociata di tipo *k-fold*: i dati vengono divisi in k blocchi, facciamo *training* su $k-1$ blocchi, facciamo *test* sul blocco rimanente, e ripetiamo finché non abbiamo fatto *test* su tutti i blocchi. Per evitare bias sistematici, i blocchi vengono generati sequenzialmente, ma soltanto dopo aver mescolato casualmente i dati. Per calcolare questo coefficiente decidiamo di dividere i dati in 10 blocchi, generati casualmente come appena spiegato. Anche in questo caso svolgiamo la convalida incrociata 1000 volte per avere una statistica sullo *score*.

Tabella 1: *Prior* scelti per ciascun parametro di ciascun modello. Tutti i parametri hanno unità di misura MeV, tranne per $\ln \epsilon$ che ha unità $\ln(\text{MeV})$. Questo non è un problema formale, perché il parametro viene sempre esponenziato prima dell'utilizzo.

Modello	$\ln \epsilon$	a_v	a_s	a_c	a_{sy}	a_p	a_w	a_{xc}	a_{st}	a_R	α_m	β_m
BW	[-6, 1]	[0, 50]	[-50, 0]	[-5, 0]	[-50, 0]	-	-	-	-	-	-	-
BW+PT	[-6, 1]	[0, 50]	[-50, 0]	[-5, 0]	[-50, 0]	[0, 50]	-	-	-	-	-	-
BW+PT+5T	[-6, 1]	[0, 50]	[-50, 0]	[-5, 0]	[-50, 0]	[0, 50]	[-100, 0]	[0, 5]	[0, 100]	[0, 50]	[-5, 0]	[0, 1]

5 Analisi e discussione

L'analisi inizia con le inferenze bayesiane sui tre modelli presentati in Sez. 3, i cui risultati presentiamo in Tab. 2. Notiamo come lo stesso parametro possa assumere valori differenti nei vari modelli, siccome aggiungere nuovi parametri introduce anche nuove correlazioni non-nulle.

Nei modelli BW e BW+PT il parametro $\ln \epsilon$ inferito è simile: per un valore tipico di energia di legame per nucleone di 8 MeV, l'errore teorico relativo risulta $\sim 1.5\%$ per questi due modelli, contro un errore sperimentale tipico del 0.01%. Questo suggerisce che i primi due modelli riescano a spiegare i dati solamente aumentando significativamente l'incertezza sul modello stesso. Al contrario, nel modello BW+PT+5T troviamo un errore teorico relativo tipico del 0.5%, molto più vicino a quello sperimentale. Il modello esteso spiega molto più facilmente i dati, ma non possiamo escludere si tratti di *overfitting*.

Il passo successivo dell'analisi è il confronto quantitativo tra i modelli impiegando i fattori di Bayes. Le *evidence* logaritmiche delle tre inferenze e le loro differenze sono riportate in Tab. 3. Per convenzione [10], un valore di $\Delta \ln Z$ dell'ordine di una decina è già un'evidenza sostanziale a favore di un modello. Guardando i risultati, possiamo affermare che i dati sperimentali sono fortemente a favore di BW+PT rispetto a BW, mentre gli stessi dati hanno un favore schiacciante per BW+PT+5T rispetto a BW+PT. Questo è in accordo con l'osservazione che abbiamo fatto discutendo dell'errore teorico. La trattazione bayesiana ci conferma che il modello esteso è di gran lunga quello migliore, quindi d'ora in poi ci concentreremo esclusivamente su quello.

Nell'inferenza bayesiana, l'introduzione di un parametro di rumore ϵ fa sì che i valori inferiti per gli altri parametri non coincidano necessariamente con il minimo degli scarti quadratici. Consideriamo quindi un approccio frequentista che trova invece i valori dei parametri che minimizzano la discrepanza tra dati e modello scelto. Il confronto tra i risultati dei due approcci ci permette di valutare quali-

tativamente l'influenza dell'errore teorico sui rimanenti parametri inferiti. Utilizzando *scipy* troviamo i parametri di BW+PT+5T minimizzando gli scarti quadratici pesati, e riportiamo i risultati in Tab. 4.

Paragonando Tab. 4 con Tab. 2, notiamo che i valori dei parametri differiscono tra i due approcci, e l'approccio frequentista restituisce errori drasticamente più piccoli. Questi errori sono di origine statistica, ma ci aspettiamo che gli errori reali siano molto più grandi e siano dominati dall'errore teorico sul modello stesso. Non possiamo confrontare i due approcci usando i fattori di Bayes, in quanto il concetto di *evidence* non esiste nella formulazione frequentista. Decidiamo invece di analizzare gli scarti tra previsioni teoriche B_i^{teo} e dati sperimentali B_i^{oss} , che riportiamo in Fig. 2.

Fig. 2 evidenzia come i due modelli BW e BW+PT siano qualitativamente comparabili nella loro capacità di descrivere i dati, e che entrambi siano nettamente inferiori al modello BW+PT+5T. Confrontando invece i risultati bayesiani e frequentisti per lo stesso BW+PT+5T notiamo una marcata differenza. L'approccio frequentista è computazionalmente molto più rapido e restituisce risultati più precisi, tuttavia l'accuratezza è scarsa. L'approccio bayesiano, invece, fornisce risultati molto più accurati, ma la precisione è sensibilmente ridotta dall'introduzione dell'errore teorico.

L'ultima parte dell'analisi è dedicata all'approccio *machine learning*, specialmente all'identificazione di un eventuale *overfitting*. Se l'accuratezza del modello dato da Eq. (4) fosse dovuta ad *overfitting*, questo non sarebbe in grado di generalizzare nuovi dati che non sono stati usati per il *training*. Possiamo escludere questa ipotesi con le procedure di convalida incrociata presentate in Sez. 4.2. Otteniamo i seguenti risultati:

$$R^2 = 0.874 \pm 0.168 ,$$

$$\text{MSE} = (0.031 \pm 0.043) \text{ MeV}^2 ,$$

intesi come media e deviazione standard delle distribuzioni di valori ottenute dalle 1000 esecuzioni ciascuno. I due

Tabella 2: Valori inferiti per tutti i parametri dei tre modelli. Il valore è la mediana del *posterior*, mentre gli errori corrispondono al 16-esimo e all'84-esimo percentile. Tutti i parametri hanno unità di misura MeV, tranne per $\ln \epsilon$ che ha unità $\ln(\text{MeV})$. La tabella (B) è il proseguimento della tabella (A).

(A)						
Modello	$\ln \epsilon$	a_v	a_s	a_c	a_{sy}	a_p
BW	$-2.028^{+0.014}_{-0.014}$	$+14.115^{+0.030}_{-0.028}$	$-13.570^{+0.069}_{-0.073}$	$-0.583^{+0.003}_{-0.003}$	$-17.019^{+0.089}_{-0.086}$	—
BW+PT	$-2.117^{+0.014}_{-0.014}$	$+14.008^{+0.028}_{-0.027}$	$-13.280^{+0.068}_{-0.067}$	$-0.573^{+0.003}_{-0.003}$	$-16.950^{+0.082}_{-0.087}$	$+5.728^{+0.268}_{-0.263}$
BW+PT+5T	$-3.220^{+0.015}_{-0.015}$	$+16.980^{+0.034}_{-0.032}$	$-27.232^{+0.170}_{-0.167}$	$-0.781^{+0.002}_{-0.002}$	$-32.490^{+0.142}_{-0.140}$	$+9.480^{+0.103}_{-0.106}$
(B)						
Modello	a_w	a_{xc}	a_{st}	a_R	α_m	β_m
BW	—	—	—	—	—	—
BW+PT	—	—	—	—	—	—
BW+PT+5T	$-22.995^{+0.472}_{-0.449}$	$+1.406^{+0.032}_{-0.032}$	$+48.607^{+0.455}_{-0.458}$	$+14.378^{+0.203}_{-0.206}$	$-1.551^{+0.077}_{-0.080}$	$+0.127^{+0.013}_{-0.012}$

Tabella 3: *Evidence* logaritmiche calcolate da *ultranest* per ciascun modello. La terza colonna è il fattore di Bayes logaritmico tra il modello e quello precedente.

Modello	$\ln Z$	$\Delta \ln Z$
BW	1508.5 ± 0.2	—
BW+PT	1717.7 ± 0.3	209.2 ± 0.4
BW+PT+5T	4466.3 ± 0.2	2748.6 ± 0.4

score ottenuti sono compatibili con i casi ideali $R^2 = 1$ e $MSE = 0$, mostrando che il modello è veramente estendibile a nuovi dati. Gli errori relativi sembrano grandi, ma evidenziano solo come una diversa separazione dei dati tra *training* e *test* influenzi la qualità dell'addestramento. Ad esempio, un modello allenato solo su nuclei pesanti non sarà adatto a fare previsioni su nuclei leggeri, e viceversa.

La verifica di *overfitting* che abbiamo svolto si basa su un modello che non include il parametro di errore teorico ϵ e in cui gli altri parametri vengono stimati con metodi frequentisti. Possiamo concludere che un modello basato su Eq. (4) è adeguato a descrivere i dati ed è generalizzabile, ma comunque non possiamo rigorosamente escludere un ipotetico *overfitting* nei risultati bayesiani.

Tabella 4: Valori dei parametri del modello BW+PT+5T trovati con un approccio frequentista, ossia minimizzando gli scarti quadratici pesati. Tutti i parametri hanno unità di misura MeV.

Parametro	Valore
a_v	$+17.04327 \pm 0.00001$
a_s	-27.20259 ± 0.00001
a_c	-0.77403 ± 0.00001
a_{sy}	-38.86928 ± 0.00002
a_p	$+10.80641 \pm 0.00001$
a_w	-39.34229 ± 0.00004
a_{xc}	$+1.00503 \pm 0.00001$
a_{st}	$+78.75190 \pm 0.00008$
a_R	$+14.88160 \pm 0.00001$
α_m	-0.49499 ± 0.00001
β_m	$+0.20450 \pm 0.00001$

6 Conclusioni

In questo lavoro, abbiamo svolto un'inferenza bayesiana sui parametri di ciascuna di tre diverse espressioni della formula di Bethe-Weizsäcker. Le tre formulazioni differiscono per livello di dettaglio fisico, e tramite il calcolo dei fattori di Bayes abbiamo verificato che aumentando il livello di dettaglio si trova effettivamente una descrizione statistica migliore.




Figura 2: Residui tra dati sperimentali e previsioni teoriche di ciascun modello considerato, in funzione del numero di nucleoni N e del numero di protoni Z dei nuclei considerati. (A), (B) e (C) si riferiscono ai risultati delle tre inferenze bayesiane, mentre (D) si riferisce ai risultati dell'approccio frequentista al modello esteso.

Se il modello frequentista minimizza gli scarti quadratici, è plausibile che appaia peggiore in questo plot?

Ci siamo poi concentrati sul modello più dettagliato, al fine di complementare l'approccio bayesiano con un approccio frequentista e un approccio basato sul *machine learning*. L'approccio frequentista è di più semplice utilizzo, ma abbiamo riscontrato che porta ad una descrizione meno accurata dei dati sperimentali. L'approccio *machine learning*, invece, ha confermato che il modello esteso è in grado di generalizzare l'addestramento a nuovi dati, mostrando che il numero di parametri non è eccessivo.

Riferimenti bibliografici

- [1] W. J. Huang et al. "The AME 2020 atomic mass evaluation (I). Evaluation of input data, and adjustment procedures*". In: *Chinese Physics C* 45.3 (2021), p. 030002. DOI: 10.1088/1674-1137/ABDDBO.
- [2] M. Wang et al. "The AME 2020 atomic mass evaluation (II). Tables, graphs and references*". In: *Chinese Physics C* 45.3 (2021), p. 030003. DOI: 10.1088/1674-1137/ABDDAF.
- [3] International Atomic Energy Agency. *AMDC - Atomic Mass Data Center*. <https://www-nds.iaea.org/amdc/>. Consultato a Maggio 2026.
- [4] C. F. v. Weizsäcker. "Zur Theorie der Kernmassen". In: *Zeitschrift für Physik* 96.7 (1935), pp. 431-458. DOI: 10.1007/BF01337700.
- [5] A. F. Saad e Z. I. Elghobary. "Theoretical predictions of nuclear binding energy for the observed nuclei: the influence of coefficients and terms in a semi-empirical mass formula". In: *Physica Scripta* 99.8 (2024), p. 085308. DOI: 10.1088/1402-4896/AD6198.
- [6] R. F. Casten. "Evolution of nuclear structure". In: *Nuclear Structure from a Simple Perspective*. Oxford: Oxford University Press, 2000, pp. 297-330. ISBN: 0-19-850724-0.
- [7] J. Buchner. "UltraNest - a robust, general purpose Bayesian inference engine". In: *Journal of Open Source Software* 6.60 (2021), p. 3001. DOI: 10.21105/joss.03001.
- [8] P. Virtanen et al. "SciPy 1.0: fundamental algorithms for scientific computing in Python". In: *Nature Methods* 17.3 (2020), pp. 261-272. DOI: 10.1038/S41592-019-0686-2.
- [9] F. Pedregosa et al. "Scikit-learn: Machine Learning in Python". In: *Journal of Machine Learning Research* 12.85 (2011), pp. 2825-2830. URL: <http://jmlr.org/papers/v12/pedregosa11a.html>.
- [10] R. E. Kass e A. E. Raftery. "Bayes Factors". In: *Journal of the American Statistical Association* 90.430 (1995), pp. 773-795. DOI: 10.1080/01621459.1995.10476572.